



순천향대학교
SOON CHUN HYANG
UNIVERSITY

제출일	2026.04.26	전공	컴퓨터소프트웨어공학과
과목	인공지능	학번	20243522
담당교수	송유정 교수님	이름	왕성훈

목차

인공지능 Term Project.....	3
주제	3
연구 배경	3
모델	3
DDPG 란	4
구현 계획	5
프레임워크.....	5
학습 환경	5
추론&테스트 환경 (Yolo26 pose).....	5
상세 프로세스	5
리스크 관리 및 대응 방안	7

인공지능 Term Project

주제

Yolo pose기반 Knowledge Distillation(지식 증류) 과정에서 강화학습을 이용한 최적의 Pruning(가지치기) 방법 탐색

연구 배경

선행 연구 [1]

IoT 환경에서 사용자의 행동에 따른 실시간 피드백이 중요해지고 있다. 이러한 실시간 피드백은 기반 시설이나 밀집 지역 등의 다양한 환경에서 활용될 수 있다. 다양한 객체 인식 모델 중에서, yolo pose모델은 객체 인식 뿐 아니라, 사람의 관절 포인트를 인식하여 관절 좌표를 활용한 더 높은 활용성을 가진다. 하지만, 이러한 Deep Learning 모델은 IoT와 같은 Edge환경에서 추론하기에 높은 연산량 (FLOPs), 높은 지연 (latency)를 갖는다. 이러한 문제로 인하여, Pruning과 같은 다양한 모델 경량화 기법이 사용된다. 하지만, 최적의 가지치기 방법을 heuristic method로 찾기에는 모델이 클 수록 힘들다. 따라서, 강화학습 에이전트를 도입한다. 강화학습 에이전트의 속성은 다음과 같다.

- 행동: 레이어 k 에 대한 pruning
- 상태: 레이어 shape, kernel 크기, 파라미터 수, 연산량(FLOPs) 등을 수치화한 1차원 벡터
- 보상: 프루닝 후 도출된 mAP, latency 등을 결합한 수치.

따라서, 강화학습 모델은, pruning을 반복하면서, 성능을 최소한으로 줄이는 방법의 Pruning조합을 찾게 된다. 즉, 민감도가 적은 레이어만 높은 pruning을 적용하고, 높은 레이어는 낮은 pruning을 적용하여 최적의 조합을 찾는다. 이렇게 하면, 기존의 heuristic pruning 대비 성능 향상을 기대할 수 있다. 또한, 지식 증류는 거대 모델(teacher)의 추론 결과를 모방하는 작은 모델(student)을 학습시키는데, 작은 모델을 거대 모델의 경량화 모델로 설정하였을 때, 지식 증류는 경량 모델의 평가 지표로 사용할 수 있다.

또한, 선행 연구에서 진행한 단순한 모델이 아닌, 복잡한 yolo pose모델을 사용한다.

모델

경량화 대상 모델: yolo26 – pose

강화학습 모델: DDPG

DDPG란

Computer Vision이나, 머신러닝 모델의 경우 상대적으로 많이 알고 있지만, 강화학습 모델에 대한 경험은 전무하여 찾아보았다.

DDPG는 연속적인 행동 공간(Continuous Action Space)에서 최적의 제어 정책을 학습하기 위해 설계된 모델 프리(Model-free), 오프 폴리시(Off-policy) 강화학습 알고리즘이다.

확률 분포를 출력하여 행동을 샘플링하는 전통적인 방법이 아닌, DDPG는 특정 상태에 대해 단일한 실수 값을 직접 산출하는 결정론적(Deterministic)구조를 지닌다.

DDPG의 모델은 다음 4가지 요소로 구성된다. [2] [3]

1. Actor-Critic 네트워크 구조

- A. Actor의 신경망 $\mu(s|\theta^\mu)$: 현재 상태 s 를 입력으로 받고, 행동 a 를 출력. 모델 경량화 파이프라인의 경우, 특정 레이어의 특징 벡터를 받아 pruning 비율(실수)을 출력
- B. Critic의 신경망 $Q(s,a|\theta^Q)$: 상태 s 와 산출한 행동 a 를 동시에 입력받음. 이 행동을 취했을 때, 미래에 얻을 수 있는 총 기대 보상값(Q-value)을 스칼라 형태로 계산, 반환

2. 네트워크 최적화

- A. Critic의 훈련: 벨만 방정식(Bellman Equation)을 기반으로, 자신이 예측한 Q-value와 실제 환경에서 측정된 보상 간의 MSE를 최소화하는 방향으로 가중치를 갱신한다.
- B. Actor의 훈련: Critic신경망이 출력하는 Q-value가 최대화되도록 자신의 가중치를 갱신한다. Chain Rule을 적용하여 Critic의 행동에 대한 gradient와 Actor의 파라미터에 대한 gradient를 곱하여 정책을 업데이트 한다.

3. 학습 안정화 기법

- A. 경험 리플레이: 에이전트가 탐색을 통해 얻은 전환 dataset을 리플레이 버퍼에 저장, 훈련 시 이 버퍼에서 무작위 미니배치를 학습함으로써 데이터 간의 시간적 상관관계를 제거하고 분산을 줄인다.
- B. 타겟 네트워크 소프트 업데이트: Actor와 Critic 각각에 대해 동일한 구조를 가진 타겟 네트워크(μ', Q')를 별도로 유지한다. 가중치는 다음과 같이 업데이트된다.
 - i. $\theta^{Q'} \leftarrow \tau \theta^{Q'} + (1 - \tau) \theta^Q$
 - ii. $\theta^{\mu'} \leftarrow \tau \theta^{\mu'} + (1 - \tau) \theta^\mu$

4. 탐색 강제

- A. DDPG는 결정론적 정책을 사용하여, 최적의 결과만 출력하는 경향이 있다. 이렇게 되면 더 나은 해를 찾지 못하고 Local Minimum에 빠질 수 있기 때문에, 행동 값에 인위적인 Noise를 더한다.
 - i. $a_t = \mu(s_t|\theta^\mu) + \mathcal{N}$
 - ii. $\mathcal{N}$ 은 일반적으로 프로세스 노이즈 또는 가우시안 노이즈이다.

구현 계획

프레임워크

- ❖ 학습: Pytorch
- ❖ 모델
 - Yolo26-pose(pre-trained): Ultralytics
 - DDPG: Stable Baselines3

학습 환경

- ❖ Ubuntu 22.04.5 LTS workstation
- ❖ GPU: NVIDIA RTX A6000

추론&테스트 환경 (Yolo26 pose)

- ❖ Raspberry pi compute module 5 (CM5)
- ❖ Debian GNU/Linux: version 13(trixie)

상세 프로세스




그림 1: 해당 프로세스는 연구 결과에 따라 변경될 수 있음.

전체 프로세스를 요약하면, 탐색과 복구(Fine-tuning) 과정으로 나눌 수 있다.

탐색 과정 [1]

DDPG Agent가 student 모델의 각 레이어를 순회한다. 레이어 t 에 대한 프로세스는 아래와 같다.

$$s_t = (t, n, c, h, w, stride, k, FLOPs[t], reduced, rest, a_{t-1})$$

t 는 레이어 index, kernel 차원은 $n \times c \times k \times k$, input 차원은 $c \times h \times w$ 이고, $FLOPs[t]$ 는 t 번째 레이어의 연산량을 의미한다. Reduced는 이전 레이어에 비해 감소된 FLOPs를 의미하고, Rest는 이후 등장하는 레이어들의 남은 연산량을 의미한다. a_{t-1} 은 이전 레이어에 대한 Action을 의미한다. Agent의 입력으로 들어가기 전에, 변수들은 $[0, 1]$ 범위로 스케일 되어 넘겨진다. Actor가 위 vector를 바탕으로 pruning 비율을 계산하고, 해당 레이어 t 를 pruning한다.

다음으로, Knowledge Distillation에서 1개의 미니배치를 두 모델에 통과시켜 Loss 계산 후, Reward한다. 이때, 가중치 업데이트는 진행하지 않는다. Reward를 Agent에게 반영하면, pruned 네트워크는 삭제하고, 원상복구한다. 이때, pruned 네트워크의 정보는 buffer에 저장한다.

Agent는 Reward를 바탕으로 가중치를 업데이트하고, 다시 원본 모델을 새로운 비율로 prune한다.

Yolo pose 모델의 경우 pruning 과정에서 cnn의 특징 추출 능력을 뭉개는 경향이 있다고 한다. 따라서 distillation 과정에서 teacher, student간의 layer wise KL-divergence를 보상 함수의 지표에 포함할 계획이다. KL divergence로 가중치 분포를 최대한 teacher와 유사하게 유지하도록 유도하기 위함이다.

위 과정을 반복한다.

참고

$$Loss = \frac{1}{N} \sum_i (y_i - Q(s_i, a_i | \theta^Q))^2$$

$$y_i = r_i - b + \gamma Q(s_i + 1, \mu(s_i + 1))$$

Critic의 손실 함수는 MSE를 사용하고, Q value의 기댓값과 실제 값의 차이를 계산한다. 실제 값(타겟)은 위와 같이 계산된다. 이때 b 는 베이스라인 보상으로, 이전 보상들의 지수 이동 평균을 의미한다고 한다.

복구 과정

최종 가장 좋은 경량화 방법을 student 모델에 적용시키고, KD를 이용하여 fine tuning

을 진행한다.

리스크 관리 및 대응 방안

본 프로젝트는 매우 실험적인 내용이므로, 실험이 원활하게 진행되지 않았을 때, 다음과 같은 대응 방안을 마련하였다.

- 모델 변경: 계획된 모델은 yolo pose 모델로, output tensor가 다차원으로 복잡하고, 모델 자체가 매우 무겁고 레이어가 복잡하게 구성 되어있다. 따라서, 본 프로젝트를 해당 모델로 기간 안에 마치지 못할 것으로 예상되면, 모델을 가벼운 모델(resnet, mobilenet 등)로 변경하여 성공 가능성을 높힐 예정이다.
- 모델 경량화 방법 변경: 계획된 방법은 Pruning(가지치기)방법이나, 객체인식 모델 특성상 pruning이 많이 적용될 수 없을 수 있으므로, Quantization(양자화)를 적용하는 방향으로 변경할 수 있다.

참고 문헌

[J. L. Z. L. H. W. L.-J. L. a. S. H. Yihui He, "AMC: AutoML for Model Compression on 1 Mobile Devices," %1 ECCV, 2018.
]

[Qcoding, 11 3 2023. [온라인]. Available: <https://qcoding.tistory.com/81>. [엑세스: 26 4 2 2026].
]

[SIES, 30 12 2022. [온라인]. Available: <https://ai-com.tistory.com/entry/RL-%EA%B0%95%ED%99%94%ED%95%99%EC%8A%B5-%EC%95%8C%EA%B3%A0%EB%A6%AC%EC%A6%98-4-DDPG>. [엑세스: 26 4 2026].
]